Практическая ценность проекта «Детектирование аномалий в логах распределенных систем»

Годовой проект, тема 85. Команда: А. Погосян, С. Поляков, А. Шевыров, Т. Мусаев.
Куратор: Д. Качкин.

Где применяется и чью боль решает. Распределенные хранилища и облачные платформы пишут миллионы строк лога в сутки. Когда что-то ломается, инженер эксплуатации (дежурная смена, SRE) ищет причину вручную или держит правила по ключевым словам. Ручной разбор не успевает за объемом, а правила шумят: в нашем наборе HDFS слово exception встречается в каждой пятой нормальной сессии, и 95% тревог по нему ложные. Проект дает сервис, который сам отмечает подозрительные сессии и показывает, какие события или слова вызвали тревогу. Выигрыш: сбой замечают раньше, чем его заметят пользователи, а дежурного не будят зря.

Как это устроено и насколько реалистично. Модель учится на нормальной работе системы и считает аномалией все, что на нее не похоже. Размеченные сбои для обучения не нужны, а именно их у компаний почти никогда нет. Разведочный анализ это поддерживает: аномалий всего 2,93%, а нормальная работа однообразна, 558 тыс. нормальных сессий сводятся к 212 различным наборам событий. Модели легкие (TF-IDF, PCA, Isolation Forest), поэтому решение можно поставить рядом с существующим сбором логов без отдельной инфраструктуры.

Трудности и их серьезность.

– Данные (высокая). Реальные логи компаний закрыты, а открытый HDFS_v1 снят в 2008 году с одного кластера за 38,7 часа. Перенос на другую систему требует переобучения на ее норме; обучение без меток делает это выполнимым.

– Устаревание (средняя). Обновление ПО меняет тексты сообщений и шаблоны событий, модель начинает шуметь. Нужны регулярный переразбор шаблонов и переобучение, это закладываем в ЧП7.

– Цена ошибок (высокая). Пропуск сбоя стоит простоя, а лишние тревоги приучают смену их игнорировать. Даже 1% ложных тревог на нашем наборе означает около 5 600 лишних срабатываний, поэтому порог настраивается под допустимую нагрузку на смену.

– Предел метода (средняя). 1,9% аномалий по составу событий не отличаются от нормы, их выдают только порядок и время событий; для них нужны последовательные модели (ЧП6).

– Безопасность и этика (низкая). Логи содержат адреса и имена узлов, поэтому обработка идет внутри контура заказчика, адреса обезличиваются. Решение оценивает работу системы, а не людей.

Как заказчик оценит качество. Основные метрики: доля найденных сбоев (recall) и число ложных тревог на смену при выбранном пороге. Дополнительно: время от начала сбоя до тревоги и доля тревог, причину которых инженер понял по объяснению модели. Проверка на практике: месяц работы в теневом режиме, тревоги модели сверяются с журналом инцидентов, а порог подбирается вместе со службой эксплуатации.